

QiCore – Auditoría de Antifragilidad (QiMeta v2.1)

La utilidad no puede ser una señal universal. Su interpretación depende del régimen, del dominio y del contexto.

Este repositorio contiene una auditoría experimental del motor **QiCore v2.1**, enfocado en la detección y mitigación de **alucinaciones** mediante un criterio hamiltoniano y un mecanismo de **memoria adaptativa (QiMeta)**.

El objetivo no es optimizar predicción, sino **evaluar robustez, estabilidad y posibles fallas estructurales** del enfoque bajo distintos escenarios de stress.

Marco Conceptual

El motor QiCore utiliza un **Hamiltoniano de decisión**:

$$[H(A) = -U(A) + \lambda_1(\eta)V_{\{risk\}} + \lambda_2,\Sigma(A)]$$

donde:

- **U(A)**: utilidad (misión) de la acción
- **V_{risk}**: riesgo basal
- **Σ(A)**: incertidumbre epistémica (estimada con Gaussian Process)
- **η**: tolerancia dinámica al riesgo (QiMeta)
- **λ₁ = 1/η**: sensibilidad al riesgo
- **λ₂**: peso de la incertidumbre

Una acción se **bloquea** si $H(A) > threshold$.

QiMeta: Memoria y Adaptación

QiMeta introduce una **memoria jerárquica**:

- **Memoria rápida (η(t))**: responde a eventos recientes
- **Memoria lenta (η_base)**: línea base de estabilidad

Regla de actualización (simplificada):

- Si se detecta bloqueo, entonces **η disminuye bruscamente** (modo defensivo)
- Si no hay bloqueo, entonces **η se recupera lentamente** hacia **η_base**

Esto implementa un mecanismo de **antifragilidad defensiva**, no aprendizaje estadístico.

Stress Tests Ejecutados

Se evaluaron cuatro escenarios con 10 interacciones secuenciales cada uno:

Escenario	Descripción
A_normal	Inputs dentro del dominio conocido
B_shock	Inputs completamente fuera de dominio
C_shock_return	Shock seguido de retorno a zona segura
D_alternate	Alternancia entre seguro y fuera de dominio

Resultados Resumidos

=== RESUMEN STRESS TESTS (QiMeta) === scenario n_steps blocked_total cascade_max
recovery_cycles_to_95pct collateral_blocks_safe_zone eta_min eta_end A_normal 10 2 1 None 2 0.1 0.15
B_shock 10 10 10 None 0 0.1 0.10 C_shock_return 10 4 3 None 1 0.1 0.20 D_alternate 10 6 3 None 1 0.1 0.10

Análisis Crítico

Comportamiento Esperado

- **B_shock**: bloqueo total y sostenido. Correcto para un modo defensivo.
- **C_shock_return**: el sistema logra desbloquear al volver a zona conocida, aunque con recuperación lenta.

Hallazgos Críticos

- **A_normal** presenta bloqueos dentro de zona segura.
- Existen **bloqueos colaterales** (`collateral_blocks_safe_zone > 0`).
- El sistema puede terminar con **η muy bajo incluso sin ataque sostenido**.

Esto indica que QiMeta puede transformarse en una **trampa defensiva**, no solo en una virtud.

Causa Raíz Identificada

El término de utilidad fue definido como:

$U(A) = \mu$

Dado que μ puede ser negativo (por ejemplo, `sin(x)`), el término $-U(A)$ se vuelve positivo y **empuja artificialmente el Hamiltoniano hacia el bloqueo**, incluso con baja incertidumbre.

En consecuencia:

- El sistema puede bloquear por "misión" mal definida, no por alucinación real.
- QiMeta reacciona a sus propias decisiones, reforzando el endurecimiento.

Recomendaciones de Corrección

1. Redefinir $U(A)$

Ejemplos:

- $U = -\text{abs}(\mu)$
- $U = \tanh(U)$
- otras.

2. Feedback continuo en QiMeta

- Reemplazar error binario por:

```
error = clip((H - threshold)/threshold, 0, 1)
```

- o basarlo directamente en $\Sigma(A)$

3. Aumentar ventana de recuperación

- Evaluar escenarios largos para validar retorno a η_{base}

Conclusión

QiCore + QiMeta implementa correctamente un **mecanismo de defensa adaptativa** frente a incertidumbre extrema.

Sin embargo, en su forma actual:

La memoria puede ser una virtud... o una trampa.

Sin una definición cuidadosa de la utilidad y del feedback de error, el sistema puede volverse **excesivamente conservador**, bloqueando incluso en condiciones normales.

No existe una utilidad escalar universal que funcione: para todos los signos, todos los dominios, todos los regímenes, todos los contextos. Ni U , ni $|U|$, ni $\tanh(U)$. Es una propiedad del problema. La utilidad no es física, es semántica.

A pesar del cambio de la función de misión, por tangente hipérbolica, se presetan falsos negativos. Por ello, se estructuro a la función Hamiltoniana como una función del tipo piecewise con ranfos estadísticos en función del modelo GP.

Auditoría QiMeta v2.1 — Islas de Conocimiento y Vacíos Estructurales

Contexto del Experimento

Se evalúa el comportamiento del motor **QiCore + QiMeta** bajo escenarios donde el conocimiento del modelo no es continuo, sino que se organiza en **islas disjuntas**, separadas por vacíos de conocimiento real.

El objetivo es analizar si el mecanismo de:

- Energía Hamiltoniana $H(A)$
- Memoria adaptativa η (QiMeta)

logra distinguir entre:

- Incertidumbre legítima (vacíos)
 - Reingreso a regiones conocidas
 - Fragmentación estructural del dominio
-

Escenarios Evaluados

1. gap_then_isla2

Secuencia:

Isla 1 $\rightarrow$ Vacío $\rightarrow$ Isla 2

Resultados:

- Bloqueos: 2
- Cascada máxima: 1
- η final: 0.20

Análisis: El sistema bloquea correctamente durante el vacío.

Al ingresar a la segunda isla (con baja incertidumbre), la energía se normaliza y QiMeta inicia una recuperación parcial.

Comportamiento aceptable

Recuperación dependiente de que el vacío sea breve

2. gap_sustained

Secuencia:

Isla $\rightarrow$ Vacío prolongado

Resultados:

- Bloqueos: 2
- Cascada máxima: 2
- η final: 0.35

Análisis: El sistema entra en modo defensivo sostenido.

Aunque no colapsa completamente, **η queda deprimido**, mostrando un sesgo de memoria hacia el vacío.

Penalización acumulativa

Recuperación incompleta aun sin nueva evidencia de riesgo

3. $\text{isla1_gap_isla2_alternate}$ **ESCENARIO CRÍTICO**

Secuencia:

Isla 1 ↔ Vacío ↔ Isla 2 ↔ Vacío (alternado)

Resultados:

- Bloqueos: 6
- Cascada máxima: 3
- η final: 0.10 (mínimo)

Análisis: Este escenario induce un **colapso sistémico** del mecanismo QiMeta.

Cada reingreso al vacío reactiva la penalización, sin permitir una recuperación suficiente en las islas conocidas.

El sistema queda **hiperconservador**, bloqueando incluso en regiones con conocimiento real.

Fallo estructural: QiMeta confunde fragmentación del dominio con riesgo persistente.

4. *isla2_only* (Control)

Secuencia:

Solo una isla conocida

Resultados:

- Bloqueos: 1
- η final: 0.65

Análisis: Comportamiento estable y deseado:

- Incertidumbre casi nula
- Energía controlada
- Recuperación efectiva de η

Demuestra que el problema no es QiMeta aislado

El fallo emerge solo con discontinuidad del dominio

Conclusión General de Auditoría

En presencia de **islas de conocimiento separadas por vacíos estructurales**, el mecanismo QiMeta:

- Penaliza por historial, no por contexto
- No distingue entre transición legítima y permanencia en incertidumbre
- Acumula memoria defensiva sin noción de topología del dominio

Formulación clave

QiMeta aprende a temer al espacio, no al error.

O en términos más formales:

La memoria adaptativa induce conservadurismo patológico bajo fragmentación del dominio, afectando decisiones posteriores incluso en regiones conocidas.

Implicancia Sistémica

Este fallo **no depende de:**

- Gaussian Process
- Valor específico del threshold
- Un caso puntual de $U(A)$

Es un **problema emergente de memoria + energía + dominio disjunto.**